

# 整体思路及知识回顾及LU分解

当我们想计算  $Ax = b$  时，

解决办法：

- 直接法：如果系数矩阵  $A$  相容且固是不衰，且右端项  $b$  不太大  
Gauss 消去及其变形：LU 分解，列主元 LU 分解，Cholesky, LDU.

- 迭代法：如果系数矩阵  $A$  机核很大且是稀疏矩阵。  
Jacobi, Gauss-Seidel, SOR

Matrice Symétrique: 对称矩阵:  $A = A^T$ , 矩阵沿着对角线对称。

Matrice Orthogonale: 正交矩阵:  $A \cdot A^T = I$ ,  $I$  是单位矩阵;  $A \cdot A^T = \alpha \cdot I$  系数

Gaussian Elimination: Gauss 消去的实质过程实际也是对矩阵进行三角形分解的过程。

高斯消去法:

在线代中：

$$A = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 2 & 1 \\ 0 & 1 & 2 \end{bmatrix} \rightarrow \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 0 & 1 & 2 \end{bmatrix} \rightarrow \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{bmatrix} = U \quad (\text{上三角矩阵})$$

LU Factorization:

LU 分解

Count on flops:

$O(\frac{2n^3}{3})$

高斯消去的每一步相当于左乘初等矩阵，在上例中：

$$A = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 2 & 1 \\ 0 & 1 & 2 \end{bmatrix} \Rightarrow E_1 * A = \begin{bmatrix} 1 & 0 & 0 \\ -1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} * \begin{bmatrix} 1 & 1 & 0 \\ 1 & 2 & 1 \\ 0 & 1 & 2 \end{bmatrix} = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{bmatrix} = A_1$$

$$\Rightarrow E_2 * A_1 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -1 & 1 \end{bmatrix} * \begin{bmatrix} 0 & 1 & 0 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{bmatrix} = U$$

$$\underbrace{E_1 * E_2 * \dots * E_n * A}_{} = U$$

消元因子乘积的是  $\Rightarrow L$

LU 分解适用范围：

if  $A$  is:

- positive definite:  $x^T A x > 0; \forall x \in \mathbb{R}^n$ . 对称且正定

- diagonally dominate:  $|a_{ii}| > \sum_{j \neq i} |a_{ij}|$ , 对角元素大于元素所在行的其它元素之和

列主元 Gauss 消去：在 Gauss 消去的过程中保留消元因子和交换行。

（挑选列中绝对值最大的  
的主元）

$$\begin{bmatrix} 0 & 2 & 1 \\ 6 & 8 & 1 \\ 4 & 4 & 1 \end{bmatrix} \xrightarrow{\text{(1,2) row exchange}} \begin{bmatrix} 6 & 8 & 1 \\ 0 & 2 & 1 \\ 4 & 4 & 1 \end{bmatrix} \rightarrow \begin{bmatrix} 6 & 8 & 1 \\ 0 & 2 & 1 \\ 2/3 & -4/3 & 1/3 \end{bmatrix} \rightarrow \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 2/3 & -2/3 & 1 \end{bmatrix} \begin{bmatrix} 6 & 8 & 1 \\ 0 & 2 & 1 \\ 0 & 0 & 1 \end{bmatrix}$$

检验  $PA = LU$

$$\begin{array}{l} \text{第一行与 } \left[ \begin{array}{ccc} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 1 \end{array} \right] \text{ 相等} \\ \text{第二行互换} \end{array} \quad \begin{bmatrix} 0 & 2 & 1 \\ 6 & 8 & 1 \\ 4 & 4 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 2/3 & -4/3 & 1 \end{bmatrix} \begin{bmatrix} 6 & 8 & 1 \\ 0 & 2 & 1 \\ 0 & 0 & 1 \end{bmatrix}$$

$P$  (置换矩阵),  $A$  (非奇异矩阵),  $L$   $U$

Cholesky Factorization: if Matrix  $A$  is:

$$\begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix} \quad \begin{array}{l} \text{对称} \\ \text{正定} \end{array}$$

- positive definite,  $x^T A x > 0, \forall x \neq 0$
- Symmetric positive definite  $\Rightarrow$  Cholesky Factorization.

若  $A$  对称,  $A = LU = L \times D \times U^T$ , 其中  $L = U^T \Rightarrow A = L \times D \times L^T$   
且正定

Growth of flops:

$$O\left(\frac{n^3}{3}\right)$$

$LU$  Algorithm: 若矩阵  $A$  对称 (Symmetric),  $A = A^T$ ,  $A = LU \Rightarrow A = L^T U^T = A^T$

Growth of flops:

$$O\left(\frac{n^3}{3}\right)$$

$$A = L^T D L^T = L D L^T, D \text{ 是对角阵.}$$

$$\begin{bmatrix} 4 & -8 & -4 \\ -8 & 18 & 14 \\ -4 & 14 & 25 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ -2 & 1 & 0 \\ -1 & 3 & 1 \end{bmatrix} \times \begin{bmatrix} 4 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 3 \end{bmatrix} \times \begin{bmatrix} 1 & -2 & -1 \\ 0 & 1 & 3 \\ 0 & 0 & 1 \end{bmatrix}$$

$$A \quad L \quad D \quad L^T$$

## 简单迭代法(补充)

迭代格式: 将  $Ax = b$  改写成等价形式  $x = Bx + f$ , 构造迭代格式:

$Ax = b$  的迭代格式

一定存在, 但未必都收敛

$$x^{(k+1)} = Bx^{(k)} + f, \quad k = 0, 1, 2 \dots$$

给定初值  $x^{(0)}$ , 反复作用上式可得到一个向量序列

$$x^{(0)}, x^{(1)}, x^{(2)}, \dots, x^{(n)} \dots$$

若,

$$\lim_{k \rightarrow \infty} x^{(k)} = x^*, \quad x^* \text{ 是方程组的解.}$$

则称迭代法收敛(Convergence), 否则为发散(Divergence).

Question 1:  $x^{(k+1)} = Bx^{(k)} + f$  何时收敛?

记  $x^*$  是精确解, 引入误差向量  $\varepsilon^{(k)} = x^{(k)} - x^*$ ,

可知“迭代序列是否收敛”等价于

$$\lim_{k \rightarrow \infty} \varepsilon^{(k)} = \vec{0} \rightarrow \text{趋于 } 0.$$

$x^*$  满足  $x^* = Bx^* + f$

与迭代格式对应相减, 得

$$\varepsilon^{(k+1)} = B\varepsilon^{(k)} = B^{(2)}\varepsilon^{(k-1)} = \dots = B^{(k+1)}\varepsilon^{(0)}$$

$\varepsilon^{(0)}$  是初值误差, 一般不为 0.

$\varepsilon^{(k)}$  是否收敛于 0 向量, 完全取决于迭代矩阵  $B$ .

若存在某种矩阵矩阵  $B$  的范数, 使得  $\|B\| < 1$ , 则迭代收敛.

谱半径: 若  $A = (a_{ij})$  是复数域上的  $n$  阶矩阵,  $\lambda_1, \lambda_2, \dots$  是  $A$  的全部特征值, 则

$$\rho(A) = \max_{1 \leq i \leq n} |\lambda_i|$$

称为  $A$  的谱半径  $\rho(A)$ .

又因为对于任意矩阵的范数都有:

$$\rho(B) \leq \|B\|$$

即最小的矩阵算子范数在数值上等于谱半径.

所以, 迭代是否收敛取决于迭代矩阵的谱半径是否  $< 1$ .

如果找到某种范数满足  $\|B\|_\infty = q < 1$ , 则迭代格式  $\varepsilon^{(k+1)} = B\varepsilon^{(k)}$

可得,  $\|\varepsilon^{(k+1)}\| \leq q^{k+1} \|\varepsilon^{(0)}\|$  前验估计

即,  $\|x^{(k+1)} - x^{(k)}\| \geq (1-q) * \|\varepsilon^{(k)}\|$  后验估计

在实际运用中多采用残差(residual)来判断数值解的精度.

$$r_k = Ax^* - Ax^{(k)} = A(x^* - x^{(k)}) = A\varepsilon^{(k)}$$

# Jacobi 迭代法

Question 1: 给定  $Ax = b$ , 如何选取迭代矩阵  $B$ , 且满足收敛性条件?

$$Ax = b \Leftrightarrow Ax - b = 0 \Leftrightarrow x = x - C * (Ax - b)$$

即

$$x = (I - CA)x + Cb$$

\*以下的 Jacobi, Gauss 等方法实际上是在讨论如何选取  $C$  的值。

写成迭代形式为  $x^{(k+1)} = (I - CA)x^{(k)} + Cb$ ,  $k = 0, 1, 2, \dots$

根据《简单迭代法》所讲, 迭代矩阵  $B = I - CA$ , 当  $\|I - CA\| < 1$  时, 迭代收敛。此时可称  $C$  是  $A$  的广义逆矩阵。 $\|A\| = 0$  时, 有  $CA = I$ 。

Jacobi 迭代: 考虑特殊情况,  $A$  的对角线元素比该行其他元素都大 (对角占优), 形式上  $A \approx D = \text{diag}(A)$ , 即

$$A = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{bmatrix} \underset{\approx}{\sim} \begin{bmatrix} a_{11} & 0 & \dots & 0 \\ 0 & a_{22} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & a_{nn} \end{bmatrix} = D$$

Cost on flops:

$O(n^3)$

则  $C = D^{-1}$ , 迭代矩阵

$$B = I - CA = I - D^{-1} * A$$

Jacobi & GS

将系数矩阵写成如下形式:  $A = D + E + F$ , 其中  $E$  是下三角,  $F$  是上三角

则迭代矩阵  $B = D^{-1} * D - D^{-1} * (D + E + F) = -D^{-1} * (E + F)$

$$x^{(k+1)} = -D^{-1} * (E + F) * x^{(k)} + b$$

$$\Leftrightarrow D x^{(k+1)} = [b - (E + F) * x^{(k)}]$$

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left[ b_i - \sum_{j \neq i} a_{ij} * x_j^{(k)} \right] - \sum_{j \neq i} a_{ij} * x_j^{(k)}, \quad i = 1, 2, \dots, n$$

Jacobi 迭代格式:

当我们只利用已更新的分量时, 可得到 Gauss-Seidel 迭代

两者计算复杂度几乎一样, 但原则上 GS 效率更高。

$O(n^3)$

Gauss-Seidel 迭代格式:

$$x_i^{(k+1)} = \frac{1}{a_{ii}} \left[ b_i - \sum_{j \neq i} a_{ij} * x_j^{(k+1)} - \sum_{j \neq i} a_{ij} * x_j^{(k)} \right], \quad i = 1, 2, \dots, n$$

# Gauss - Seidel 迭代法

Question 2: 根据简单迭代推导公式,  $x = x + C(b - Ax) = (I - CA)x + Cb$

GS迭代的广义矩阵  $C$  是什么?

Gauss - Seidel 迭代的矩阵形式:

$$Dx^{(k+1)} = b - Lx^{(k+1)} - Ux^{(k)}$$

$$(D+L)x^{(k+1)} = b - Ux^{(k)}$$

即

$$x^{(k+1)} = - (D+L)^{-1}Ux^{(k)} + (D+L)^{-1}b$$

若记  $G$  为系数矩阵  $A$  的下三角矩阵 (连同对角线元素), 上式即为

$$x^{(k+1)} = -G^{-1}Ux^{(k)} + G^{-1}b = G^{-1}(G-A)x^{(k)} + G^{-1}b.$$

收敛性分析:

① 严格对角占优 ( $\bar{a}$  Diagonale Dominante Stricte)

$$|\alpha_{ii}| > \sum_{j \neq i, j=1}^n |\alpha_{ij}|, \quad i=1, 2, \dots, n.$$

此时 Jacobi, GS 均收敛

②  $A$  对称正定 (Symétrique définit positive), GS 收敛

③  $A$  以及  $(2D-A)$  均对称正定, Jacobi 收敛.

SOR (Successive

Over Relaxation) 超松弛迭代

- 已知第  $k$  步的迭代值  $x^{(k)}$ , 利用 GS 计算得到  $\overline{x}^{(k+1)}$  中间值
- 取两步迭代的加权平均值.

$$x^{(k+1)} = \underbrace{(1-w)x^{(k)}}_1 + \underbrace{w\overline{x}^{(k+1)}}_2 = x^{(k)} + w(\overline{x}^{(k+1)} - x^{(k)})$$

$$w = \frac{2}{1 + 1 - \rho(D^{-1} \cdot (E+F))^2}$$

本质上是 SG 的加权平均

Weighted average.

## Algorithmes itératifs de relaxation

On cherche une solution  $x^*$  telle que  $Ax^* = b$  avec un algorithme itératif de type  $x^{(p+1)} = M^{-1}N x^{(p)}$ .

Algo itératif de relaxation

Méthode de gradient.

$$A = M - N$$

Algo itératif de relaxation :

$$A = D - E - F, \text{ avec } D = \begin{bmatrix} \ddots & & \\ & \ddots & \\ & & 0 \end{bmatrix}, E = \begin{bmatrix} 0 & & \\ -a_{11} & 0 & \\ & \ddots & 0 \end{bmatrix}, F = \begin{bmatrix} 0 & -a_{21} & \\ 0 & \ddots & \\ & & 0 \end{bmatrix}$$

associé :  $\{x^{(p)} \in \mathbb{R}^n\}$ 

$$\underbrace{x^{(p+1)}}_{\text{对角阵}} = x^{(p)} + M^{-1} \cdot r^{(p)}, \text{ avec } r^{(p)} = b - A \cdot x^{(p)} \text{ le vecteur résidu.}$$

Génération d'une itération : en dehors du calcul du résidu : résolution d'un système de matrice  $M$ .

$$Ax^* = b \Leftrightarrow (M - N)x^* = b$$

$$\Leftrightarrow Mx^* = Nx^* + b$$

$$\Leftrightarrow x^* = M^{-1}Nx^* + M^{-1}b$$

$$\Leftrightarrow x^* = M^{-1}(M - A)x^* + M^{-1}b$$

$$\Leftrightarrow \underbrace{x^*}_{?} = x^* + M^{-1}[b - Ax^*]$$

2 variantes :

2 variantes (2種類)

- Algo de Gauss-Siedel :  $M = D - E$ ,  $N = F$ .

$$Mx^* = Nx^* + b$$

$$\Leftrightarrow (D - E)x^{(p+1)} - Fx^{(p)} = b \Leftrightarrow x^{(p+1)} = (D - E)^{-1}[b - Ax^{(p)}] + x^{(p)}$$

- Algo de Jacobi :  $M = D$ ,  $N = E + F$ .

$$Mx^* = Nx^* + b$$

$$\Leftrightarrow Dx^{(p+1)} - (E + F)x^{(p)} = b \Leftrightarrow x^{(p+1)} = b^{-1}[b - Ax^{(p)}] + x^{(p)}$$

Condition d'arrêt :  $\frac{\|Ax^{(p+1)} - b\|}{\|b\|} < \epsilon$

收敛的充分条件:

Condition Nécessaire et Suffisante de Convergence:

$$\lim_{P \rightarrow +\infty} (\rho(M^{-1} \cdot N))^P = 0 \Leftrightarrow \rho(M^{-1} \cdot N) < 1$$

谱半径

\*理论详见《简单迭代法(补充)》 - Question 1.

收敛的充分条件:  
Condition Suffisante de Convergence:

- Si  $A$  est à Diagonale Dominante Stricte  $\Rightarrow$  Convergence pour Gauss.
- $\forall x_0, y_i, |a_{ii}| > \sum_{j=1, j \neq i}^n |a_{ij}|$
- Si  $A$  est à Diagonale Dominante et  $\exists k \in \{1, \dots, n\}$ ,  
 $|a_{kk}| > \sum_{j \neq k}^n |a_{kj}| \Rightarrow$  CG
- Si  $A$  est symétrique définie positive  $\Rightarrow$  Convergence pour Gauss

Méthode SOR: 详见课件 « Méthodes itératives » - P13

Méthode de la Steepest-

Descent:

Si  $A$  est Symétrique définie positive,  $x^{(0)} \in \mathbb{R}^n$   
et  $x^{(P+1)} = x^{(P)} + \lambda \rho r^{(P)}$   $\rightarrow$  direction de descente (vecteur)  
progression dans la direction de descente, scalaire,  
下降方向的进阶步长(标量)

Direction:  $r^{(P)} = -\text{grad } F(x^{(P)}) = b - Ax^{(P)}$

Progression:  $\lambda^{(P)} = \frac{(r^{(P)})^T \cdot r^{(P)}}{(r^{(P)})^T \cdot A \cdot r^{(P)}},$  qui minimise dans la direction  $r^{(P)}$ .

## QR Factorization

Householder 变换.

\* 对任意模长为 1 的向量  $w \in R^n$ , 检验反射矩阵  $H = I - 2ww^T$ , 满足

$$H = H^T, \quad H \cdot H = I, \quad \text{即 } H \text{ 为对称正交矩阵.}$$

✓  
对称矩阵
↓  
正交矩阵.

记起平面(过原点, 以  $w$  为法向量),

$$S = \{x \mid w^T x = 0, \forall x \in R^n\} \quad \text{即 } S \text{ 平面是与 } w^\perp \text{ 垂直的平面.}$$

若  $S$  是  $R^n$  子空间, 维数取秩为  $n-1$ , 则任意向量  $\exists g \in R^n$  使得  $g \in S$ 子空间  $S$  和  $\text{span}\{w\}$  正交分解:

$$z = x + y, \quad z \in S, \quad y = \overset{\rightarrow}{x \cdot w} w, \quad x \in R$$

系数

$$\text{通. } H_z = H_x + Hy = x + (I - 2ww^T)y = x + y - 2ww^T x \cdot w = x - y$$

从而上式反射矩阵 (Householder 变换) 可看作是以  $S$  为镜面的反射.\* 给定两个模长相等的向量  $x, y \in R^n$ , 则存在反射变换  $H$ . 使得

$$Hx = y \quad w = \frac{x - y}{\|x - y\|}$$

## Décomposition en valeurs singulières

### SVD Factorization 奇异值分解.

定义：矩阵的奇异值分解是指，将一个非零的  $m \times n$  实矩阵  $A$ ,  $A \in \mathbb{R}^{m \times n}$ ,

表示为以下三个实矩阵乘积形式的运算，即是行矩阵的因子分解：

奇异向量 singular vector

$m \times m$

$m \times m$

$m \times n$

$$A = U \Sigma V^T$$

$$\Sigma = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_p)$$

其中， $U$  是  $m$  阶正交矩阵 (orthogonal matrix),  $\sigma_1 > \sigma_2 > \dots > \sigma_p > 0$

$\Sigma$  是由降序排列的非负的对角线元素组成的  $m \times n$  矩形对角矩阵

$V$  是  $n$  阶正交矩阵。

$U$  的列向量称为左奇异向量， $V$  的列向量称为右奇异向量。

$\sigma_i$  称为矩阵  $A$  的奇异值 (singular value).

只要矩阵  $A$  是一个实矩阵，其奇异值分解一定存在。

奇异值分解计算步骤：

$A$  为一个  $m \times n$  实矩阵，有：

① 构造  $n$  阶实对称矩阵  $W = A^T A$

② 计算  $W$  的特征值和特征向量

求解特征方程  $(W - \lambda I)x = 0$ ，得到特征值  $\lambda_i$ ，并将特征值由大到小排列， $\lambda_1 > \lambda_2 > \dots > \lambda_n > 0$ ，将特征值  $\lambda_i$  ( $i = 1, 2, \dots, n$ ) 代入特征方程求得对应的特征向量。

③ 求得  $n$  阶正交矩阵  $V$  (利用上述求得“特征向量”)。

将特征向量单位化，得到单位特征向量  $v_1, v_2, \dots, v_n$ ，构成  $n$  阶

正交矩阵  $V$ :  $V = [v_1, v_2, \dots, v_n]$ .

④ 求得  $m \times n$  对称矩阵  $\Sigma$  (利用上述求得“特征值”)。

计算  $A$  的奇异值  $\sigma_i = \sqrt{\lambda_i}$ ,  $i = 1, 2, \dots, n$ .

构造  $m \times n$  矩形对角矩阵  $\Sigma$ ，主对角线元素是奇异值，其余元素是零。 $\Sigma = \text{diag}(\sigma_1, \sigma_2, \dots, \sigma_n)$ .

⑤ 求得  $m$  阶正交矩阵  $U$  (利用上述求得的  $V$  和  $\Sigma$ )。

i. 求  $U$ .

对于  $A$  的前  $r$  个正奇异值，令  $u_j = \frac{1}{\sigma_j} A v_j$ ,  $j = 1, 2, \dots, r$

得到  $U_1 = [u_1, u_2, \dots, u_r]$

ii. 求  $U_2$ .

求  $A^T$  的零空间的一组线性无关基  $\{u_{r+1}, u_{r+2}, \dots, u_m\}$ .

令  $U_2 = [u_{r+1} \ u_{r+2} \ \dots \ u_n]$

iii. 得到  $U = [U_1 \ U_2]$ .

SVD法缺点：不适合处理大型稀疏矩阵.